

# MODELOS ESTATÍSTICOS APLICADOS A RELAÇÕES DENDROMÉTRICAS

Uma Viagem pela Estatística

Prof. Luan Fiorentin

Laboratório de Estatística e Geoinformação  
Departamento de Estatística  
Universidade Federal do Paraná

22 de fevereiro de 2021



# Uma viagem pela Estatística!

- ▶ Introdução.
- ▶ Biometria Florestal.
- ▶ Modelos Lineares.
- ▶ Modelos Lineares Generalizados.
- ▶ Modelos Lineares Generalizados Mistos.
- ▶ Modelos Não Lineares.
- ▶ Modelos Não Lineares Generalizados.
- ▶ Modelos Não Lineares Generalizados Mistos.
- ▶ Modelos Multivariados.
- ▶ Outras Classes de Modelos.
- ▶ Considerações Finais.



Figura 1. Foto de Lukas no Pexels.

# Introdução

- ▶ **Inventário florestal** é um procedimento para coletar informações qualitativas de características da floresta.
- ▶ Logo, devemos concluir a respeito de características da floresta a partir de uma **amostra**.
- ▶ Principais **variáveis**:
  - ▶ Volume de madeira na floresta;
  - ▶ Altura das árvores;
  - ▶ Número de espécies;
  - ▶ Entre outras.

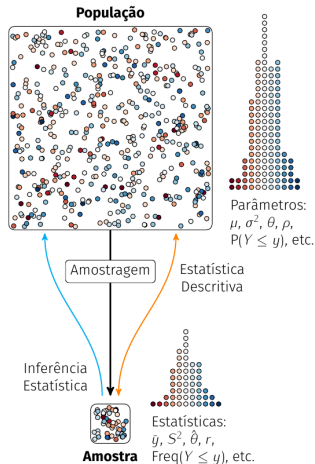


Figura 2. Extraído de Walmes Zeviani. Disponível em: <http://leg.ufpr.br/walmes/Tikz>.

# Biometria Florestal

- ▶ É a área da Ciência que estuda a **medição das árvores e das florestas**, com finalidade de entender o seu crescimento ao longo do tempo.
  - ▶ Volume; Altura; Diâmetro; entre outras.
- ▶ **Relações Dendrométricas** são associações desenvolvidas entre variáveis mensuradas em árvores.
  - ▶ Altura e diâmetro (relação hipsométrica);
  - ▶ Volume e diâmetro;
  - ▶ Diâmetro de copa e diâmetro;
  - ▶ Espessura de casca e idade.




Figura 3. Dinâmica da forma da árvore.

# Biometria Florestal

- ▶ Variáveis de **difícil** obtenção:
  - ▶ Volume total/individual;
  - ▶ Volume de casca de madeira;
  - ▶ Altura total/comercial;
  - ▶ Diâmetro de copa;
  - ▶ Entre outras.
- ▶ Podemos coletar informações **específicas** das árvores na floresta.
- ▶ **Relacionar** variáveis de fácil acesso com variáveis complexas.




Figura 4. Extraído de Fiorentin et al. (2019).

# Biometria Florestal

- ▶ Na modelagem dendrométrica, procuramos estudar a **relação** entre duas ou mais variáveis  $Y$  e  $X$ :

$$Y = f(X).$$

- ▶ Cada observação é composta por duas partes:
  - ▶ **Previsível** (ou controlada).
  - ▶ **Aleatória** (não previsível ou não controlada).

$$\text{observação} = \text{previsível} + \text{aleatória}.$$

- ▶ Parte previsível incorpora o **conhecimento sobre a variável**, sendo expressa por uma função matemática.
- ▶ Parte aleatória deve obedecer algum **modelo de probabilidade**.

- ▶ **Matematicamente**, podemos descrever a relação como

$$y_i = \theta + \epsilon_i,$$

em que:

- ▶  $y_i$  é a observação  $i$  da variável resposta  $Y$ ;
- ▶  $\theta$  é um parâmetro de efeito fixo, comum a todas as observações;
- ▶  $\epsilon_i$  é o erro da observação  $i$ , ou efeito residual ou aleatório, sendo  $\epsilon_i = y_i - \theta$ .
- ▶  $\epsilon_i$  pode ser resultante de outras variáveis que não foram controladas (ou não são controláveis). Logo, elas não estão explícitas no modelo.

# Biometria Florestal - Exemplo 1

- ▶ **Exemplo:** Interesse em estimar a altura total de um povoamento florestal.
  - ▶ Foram mensuradas as variáveis altura, diâmetro e idade em nível de indivíduo.
  - ▶ **Pergunta:** o que fazer com as árvores em que a altura não foi mensurada no inventário florestal?
  - ▶ **Resposta:** estimar a altura das árvores.




Figura 5. Árvores amostradas em colorido.



# Biometria Florestal - Exemplo 1

- ▶ **Exemplo:** Amostra coletada:

altura	diâmetro
8.0	15.0
8.3	15.5
10.0	16.0
11.7	16.5
12.0	17.0

- ▶ Modelo constante:

$$y_i = \theta + \epsilon_i$$

- ▶ Modelo linear simples:

$$y_i = \beta_0 + \beta_1 \text{diâmetro}_i + \epsilon_i$$

Podemos estimar a altura das árvores ( $y_i$ ) de duas formas:

- ▶ Usando apenas os valores de  $y_i$ .
- ▶ Usando a relação de  $y_i$  com diâmetro das árvores ( $x_i$ ).

# Biometria Florestal - Exemplo 1

- ▶ **Exemplo:** Considerando que a altura média das árvores é  $\hat{\mu} = 10$  metros, então  $\hat{y}_i$  pode ser descrita por:

$$\hat{y}_i = 10 + e_i,$$

em que:

- ▶  $\hat{\theta} = \hat{\mu}$ ;
- ▶  $e_i$  determinará a altura de cada árvore em função de diversos fatores:

$$e_i = f(\text{diâmetro, sítio, idade, ...}).$$

Conforme relacionamos a altura com outras variáveis, ganhamos informação e **diminuímos o erro**.




Figura 6. Modelagem da Altura.

# Biometria Florestal - Exemplo 1

- ▶ **Exemplo:** Considerando que a altura média das árvores é uma  $f(\text{diâmetro})$ , então  $\hat{y}_i$  pode ser descrita por:

$$\hat{y}_i = -26.48 + 2.28\text{diâmetro}_i + e_i,$$

em que:

- ▶  $\hat{\theta} = \hat{\mu}$ ;
- ▶  $e_i$  determinará a altura de cada árvore em função de diversos fatores:

$$e_i = f(\text{sítio, idade, } \dots).$$

Conforme relacionamos a altura com outras variáveis, ganhamos informação e **diminuímos o erro**.




Figura 7. Modelagem da Altura dado o Diâmetro.

# Modelos Lineares

- ▶ É uma classe de modelos onde o **parâmetro** ocorre de forma **linear**.
- ▶ Casos **especiais**:
  - ▶ Análise de variância (ANOVA).
  - ▶ Análise de regressão linear.
- ▶ **Análise de variância**: compara simultaneamente  $k$  médias.
- ▶ **Análise de regressão linear**: estuda a relação entre variáveis  $Y$  e  $X$ :
  - ▶ Regressão linear simples.
  - ▶ Regressão linear múltipla.




Figura 8. Representações esquemáticas dos modelos de ANOVA e regressão linear simples.

# Modelos Lineares - Regressão Linear Simples

- ▶ **Modelo de regressão linear simples** é definido por uma reta que estabelece a relação entre uma variável resposta ( $y_i$ ) e uma explicativa ( $x_i$ ):

$$y_i = \beta_0 + \beta_1 x_i + \epsilon_i,$$

em que:

- ▶  $i$  é o índice da observação;
  - ▶  $\beta_0$  é o intercepto da reta;
  - ▶  $\beta_1$  é o coeficiente angular da reta;
  - ▶  $\epsilon$  é o erro aleatório.
- ▶ Definimos que os erros seguem uma **distribuição normal** de média zero e variância constante, ou seja,  $\epsilon \sim N(0, \sigma^2)$ .
  - ▶ Ainda, supomos que erros associados a diferentes observações sejam **não correlacionados**, então  $Cov(\epsilon_i, \epsilon'_i) = 0$ .

# Modelos Lineares - Regressão Linear Simples




Figura 9. Componentes do modelo. Extraído de Walmes Zeviani. Disponível em: <http://leg.ufpr.br/walmes/Tikz>.

# Modelos Lineares - Regressão Linear Simples

- ▶ **Média** de  $y_i$ :

$$E(y_i|x_i) = \beta_0 + \beta_1 x_i.$$

- ▶ **Variância** de  $y_i$ :

$$Var(y_i|x_i) = \sigma^2.$$

- ▶ **Interpretação** dos parâmetros:

- ▶  $\beta_1$  expressa a alteração no valor esperado de  $y_i$  associado ao acréscimo de uma unidade em  $x_i$ .
- ▶  $\beta_0$  é o valor esperado de  $y_i$  quando  $x_i = 0$ .

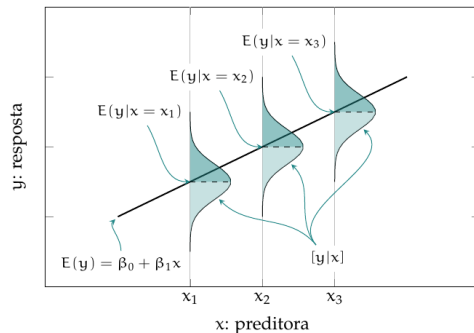


Figura 10. Valor esperado da resposta. Extraído de Walmes Zeviani. Disponível em: <http://leg.ufpr.br/walmes/Tikz>.

# Modelos Lineares - Regressão Linear Simples

- **Valores preditos:** A predição de valores estimados para a resposta depende de valores da variável preditora:

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i.$$

- **Resíduos** são erros de predição ao se utilizar um modelo para descrever a relação entre variáveis:

$$e_i = y_i - \hat{y}_i.$$




Figura 11. Resíduos. Extraído de Walmes Zeviani. Disponível em: <http://leg.ufpr.br/walmes/Tikz>.



# Modelos Lineares - Regressão Linear Simples

- ▶ **Estimação dos parâmetros:** Note que o resíduo ( $\epsilon_i$ ) é função dos parâmetros desconhecidos  $\beta_0$  e  $\beta_1$ .
- ▶ Precisamos de um **critério** para definir valores ótimos de parâmetros.
- ▶ Critério de **mínimos quadrados** consiste em minimizar a soma de quadrados dos resíduos ( $SSE$ ):

$$SSE(\beta_0, \beta_1) = \sum_{i=1}^n (y_i - (\beta_0 + \beta_1 x_i))^2.$$




Figura 12. Minimização da SSE. Extraído de Walmes Zeviani. Disponível em: <http://leg.ufpr.br/walmes/Tikz>.

# Modelos Lineares - Regressão Linear Simples

- ▶ Abordagem padrão é usar **cálculo diferencial**:
  - ▶ Obter **vetor gradiente** (vetor de derivadas parciais) de  $\beta_0$  e  $\beta_1$ ;
  - ▶ Resolver o **sistema de equações lineares** (igualar a zero e isolar  $\beta_0$  e  $\beta_1$ ):

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x},$$
$$\hat{\beta}_1 = \frac{\sum_{i=1}^n x_i y_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2},$$

sendo  $\bar{x}$  e  $\bar{y}$  a média de cada variável.

Já a variância é

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n - 2}.$$




Figura 13. Minimização da SSE. Extraído de Walmes Zeviani. Disponível em: <http://leg.ufpr.br/walmes/Tikz>.

## Modelos Lineares - Regressão Linear Simples - Exemplo 2

- ▶ O problema consiste em **estimar a altura total** de árvores de um inventário florestal realizado em determinada idade.
- ▶ **Dados** disponíveis:
  - ▶ Altura ( $H$ ) → Resposta.
  - ▶ Diâmetro ( $D$ ) → Preditora.
- ▶ Modelo **teórico**:

$$H_i = \beta_0 + \beta_1 D_i + \epsilon_i.$$

- ▶ **Valor esperado:**

$$E(H_i) = \hat{\beta}_0 + \hat{\beta}_1 D_i.$$




Figura 14. Exemplo 2

## Modelos Lineares - Regressão Linear Simples - Exemplo 2

- ▶ O problema consiste em **estimar a altura total** de árvores de um inventário florestal realizado em determinada idade.
- ▶ **Dados** disponíveis:
  - ▶ Altura ( $H$ ) → Resposta.
  - ▶ Diâmetro ( $D$ ) → Preditora.
- ▶ Modelo **teórico**:

$$H_i = \beta_0 + \beta_1 D_i + \epsilon_i.$$

- ▶ **Valor esperado:**

$$E(H_i) = \hat{\beta}_0 + \hat{\beta}_1 D_i.$$




Figura 15. Exemplo 2

# Modelos Lineares - Regressão Linear Múltiplo

- ▶ **Modelo de regressão linear múltiplo** é definido por função que estabelece a relação entre uma variável resposta ( $y_i$ ) e múltiplas explicativas ( $x_{i1}, \dots, x_{ip}$ ):

$$y_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip} + \epsilon_i,$$

em que:

- ▶  $i$  é o índice da observação;
  - ▶  $\beta_0$  é o intercepto;
  - ▶  $\beta_j$  é o parâmetro, sendo  $j = 1, \dots, p$ ;
  - ▶  $x_j$  é a variável preditora, sendo  $j = 1, \dots, p$ ;
  - ▶  $\epsilon$  é o erro aleatório.
- ▶ Definimos que os erros seguem uma **distribuição normal** de média zero e variância constante, ou seja,  $\epsilon \sim N(0, \sigma^2)$ .
  - ▶ Ainda, supomos que erros associados a diferentes observações sejam **não correlacionados**, então  $Cov(\epsilon_i, \epsilon'_i) = 0$ .

# Modelos Lineares - Regressão Linear Múltiplo

- ▶ **Média** de  $y_i$ :

$$E(y_i | \mathbf{x}_i = (x_{i1}, \dots, x_{ip})') = \beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip}.$$

- ▶ **Variância** de  $y_i$ :

$$Var(y_i | \mathbf{x}_i = (x_{i1}, \dots, x_{ip})') = \sigma^2.$$

- ▶ **Interpretação** dos parâmetros:

- ▶  $\beta_j$  representa a alteração esperada na resposta ( $y_i$ ) para uma unidade a mais em  $x_{ij}$ , quando as demais preditoras são mantidas fixas.

# Modelos Lineares - Regressão Linear Múltiplo

- **Valores preditos:** A predição de valores estimados para a resposta depende de valores das variáveis predictoras:

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \dots + \hat{\beta}_p x_{ip}.$$

- **Resíduos** são erros de predição ao se utilizar um modelo para descrever a relação entre variáveis:

$$e_i = y_i - \hat{y}_i.$$




Figura 16. Resíduos. Extraído de Walmes Zeviani. Disponível em: <http://leg.ufpr.br/walmes/Tikz>.

# Modelos Lineares - Regressão Linear Múltiplo

- ▶ **Notação matricial:** Modelo de regressão linear múltiplo é dado por

$$y = x\beta + \epsilon,$$

em que:

- ▶  $y = (y_1, \dots, y_n)'$  de dimensão  $n \times 1$ ;
- ▶  $x = (1_i, x_{i1}, \dots, x_{ip})'$  de dimensão  $n \times (p + 1)$ ;
- ▶  $\beta = (\beta_0, \beta_1, \dots, \beta_p)'$  de dimensão  $(p + 1) \times 1$ ;
- ▶  $\epsilon = (\epsilon_1, \dots, \epsilon_n)'$  de dimensão  $n \times 1$ .



# Modelos Lineares - Regressão Linear Múltiplo

- ▶ **Estimação dos parâmetros:** Estimação de mínimos quadrados baseia-se, novamente, na determinação de  $\beta_0, \beta_1, \dots, \beta_p$  que minimizem a soma de quadrados de resíduos dada por

$$SSE(\beta_0, \beta_1, \dots, \beta_p) = \sum_{i=1}^n (y_i - (\beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip}))^2.$$

Em notação matricial:  $SSE(\boldsymbol{\beta}) = (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})'(\mathbf{y} - \mathbf{X}\boldsymbol{\beta})$ .

- ▶ Estimador de mínimos quadrados em notação matricial é dado por

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}.$$

- ▶ Estimador de variância é dado por

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n - p}.$$

## Modelos Lineares - Regressão Linear Múltiplo - Exemplo 3

- ▶ O problema consiste em **estimar o volume total** de árvores de um inventário florestal realizado em determinada idade.
- ▶ **Dados** disponíveis:
  - ▶ Volume ( $H$ ) → Resposta.
  - ▶ Diâmetro ( $D$ ) → Preditora.
- ▶ Modelo **teórico**:

$$V_i = \beta_0 + \beta_1 D_i + \beta_2 D_i^2 + \epsilon_i.$$

- ▶ **Valor esperado:**

$$E(H_i) = \hat{\beta}_0 + \hat{\beta}_1 D_i + \hat{\beta}_2 D_i^2.$$




Figura 17. Exemplo 3

## Modelos Lineares - Regressão Linear Múltiplo - Exemplo 3

- ▶ O problema consiste em **estimar o volume total** de árvores de um inventário florestal realizado em determinada idade.
- ▶ **Dados** disponíveis:
  - ▶ Volume ( $H$ ) → Resposta.
  - ▶ Diâmetro ( $D$ ) → Preditora.
- ▶ Modelo **teórico**:

$$V_i = \beta_0 + \beta_1 D_i + \beta_2 D_i^2 + \epsilon_i.$$

- ▶ **Valor esperado:**

$$E(H_i) = \hat{\beta}_0 + \hat{\beta}_1 D_i + \hat{\beta}_2 D_i^2.$$




Figura 18. Exemplo 3

# Modelos Lineares Generalizados

- ▶ O comportamento da resposta pode ser estudado por meio de modelos **probabilísticos**.
- ▶ Modelos disponíveis para variáveis:
  - ▶ Discreta → Poisson;
  - ▶ Contínua → Normal, Gamma;
  - ▶ Binária → Binomial, Hipergeométrica;
  - ▶ Limitada em intervalo → Beta.
- ▶ Escolha do modelo depende da **natureza** da resposta e análises **gráficas**.




Figura 19. Modelo linear generalizado. Extraído de Walmes Zeviani. Disponível em: <http://leg.ufpr.br/walmes/Tikz>.

# Modelos Lineares Generalizados

- ▶ Definido pela **especificação** de três componentes:
  - ▶ **Componente aleatório**: conjunto de variáveis aleatórias independentes ( $y_i$ ) com distribuição pertencente à família exponencial, e vetor de parâmetros  $\theta, \phi$ :

$$f_e(y_i; \theta, \phi) = \exp \left\{ \frac{y_i \theta - b(\theta)}{a(\phi)} + c(y_i; \phi) \right\},$$

em que  $a, b, c$  são funções adequadas.

- ▶ **Componente sistemático**: é o preditor linear do modelo, em que as variáveis são inseridas por meio de uma combinação linear de parâmetros:

$$\eta_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip}.$$

- ▶ **Função de ligação**: É uma função real, monótona e diferenciável, que conecta o componente sistemático ao aleatório:

$$g(\mu_i) = \eta_i \quad \text{e} \quad \mu_i = g^{-1}(\eta_i),$$

em que  $\mu_i = E(y_i | \mathbf{x}_i = (x_{i1}, \dots, x_{ip})')$ .

## Modelos Lineares Generalizados - Exemplo 4

- ▶ O problema consiste em **estimar o volume total** de árvores de um inventário florestal realizado em determinadas idades.
- ▶ **Dados** disponíveis:
  - ▶ Volume ( $V$ ) → Resposta.
  - ▶ Idade ( $I$ ) → Preditora.
- ▶ Modelo **teórico** com distribuição Gamma e função de ligação logarítmica:

$$V_i = \exp(\beta_0 + \beta_1 I_i + \epsilon_i).$$

- ▶ **Valor esperado:**

$$E(V_i) = \exp(\hat{\beta}_0 + \hat{\beta}_1 I_i).$$




Figura 20. Exemplo 4

## Modelos Lineares Generalizados - Exemplo 4

- ▶ O problema consiste em **estimar o volume total** de árvores de um inventário florestal realizado em determinadas idades.
- ▶ **Dados** disponíveis:
  - ▶ Volume ( $V$ ) → Resposta.
  - ▶ Idade ( $I$ ) → Preditora.
- ▶ Modelo **teórico** com distribuição Gamma e função de ligação logarítmica:

$$V_i = \exp(\beta_0 + \beta_1 I_i + \epsilon_i).$$

- ▶ **Valor esperado:**

$$E(V_i) = \exp(\hat{\beta}_0 + \hat{\beta}_1 I_i).$$




Figura 21. Exemplo 4. Dados extraídos do pacote forestmangr no R.

## Modelos Lineares Generalizados - Exemplo 4

- ▶ O problema consiste em **estimar o volume total** de árvores de um inventário florestal realizado em determinadas idades.
- ▶ **Dados** disponíveis:
  - ▶ Volume ( $V$ ) → Resposta.
  - ▶ Idade ( $I$ ) → Preditora.
- ▶ Modelo **teórico** com distribuição Gamma e função de ligação logarítmica:

$$V_i = \exp(\beta_0 + \beta_1 I_i + \epsilon_i).$$

- ▶ **Valor esperado:**

$$E(V_i) = \exp(\hat{\beta}_0 + \hat{\beta}_1 I_i).$$




Figura 22. Exemplo 4. Dados extraídos do pacote forestmangr no R.



# Modelos Lineares Generalizados Mistos

- ▶ Em **dados longitudinais**, a resposta é mensurada no mesmo indivíduo em diversas ocasiões ao longo do tempo.
- ▶ Observações tomadas ao longo do tempo são **não independentes**.
- ▶ Qual a solução? Incluir **efeitos aleatórios** no modelo.
- ▶ **Modelo misto:**

Efeitos Fixos + Efeitos Aleatórios.




Figura 23. Observações tomadas em diferentes tempos. Dados extraídos do pacote forestmangr no R.

# Modelos Lineares Generalizados Mistos

- ▶ Em **dados longitudinais**, a resposta é mensurada no mesmo indivíduo em diversas ocasiões ao longo do tempo.
- ▶ Observações tomadas ao longo do tempo são **não independentes**.
- ▶ Qual a solução? Incluir **efeitos aleatórios** no modelo.
- ▶ **Modelo misto:**

Efeitos Fixos + Efeitos Aleatórios.




Figura 24. Observações tomadas em diferentes tempos. Dados extraídos do pacote forestmangr no R.

# Modelos Lineares Generalizados Mistos

- ▶ Em **dados longitudinais**, a resposta é mensurada no mesmo indivíduo em diversas ocasiões ao longo do tempo.
- ▶ Observações tomadas ao longo do tempo são **não independentes**.
- ▶ Qual a solução? Incluir **efeitos aleatórios** no modelo.
- ▶ **Modelo misto:**

Efeitos Fixos + Efeitos Aleatórios.




Figura 25. Observações tomadas em diferentes tempos. Dados extraídos do pacote forestmangr no R.

# Modelos Lineares Generalizados Mistos

- ▶ **Independência** entre observações é obtida dado os efeitos aleatórios.
- ▶ Efeitos aleatórios induzem a uma **estrutura de correlação** entre as respostas medidas no mesmo indivíduo.
- ▶ Em geral, as correlações são positivas, mas **decrecem** ao longo do tempo.
- ▶ **Correlação positiva**: indivíduo que apresenta valor *acima da média* no tempo ( $t$ ), tende a apresentar valor *acima da média* em tempo posterior ( $t + u$ ).




Figura 26. Observações tomadas em diferentes tempos. Dados extraídos do pacote forestmangr no R.

# Modelos Lineares Generalizados Mistos

- ▶ **Notação matricial** utilizada para descrever o indivíduo  $i$ , dada por

$$y_i = z_i\beta + x_ib_i + \epsilon_i,$$

em que:

- ▶  $y_i$  é vetor de resposta;
- ▶  $x_i$  e  $z_i$  é matriz associada ao efeito fixo e aleatório, respectivamente;
- ▶  $\beta$  e  $b_i$  é vetor de efeito fixo e aleatório, respectivamente;
- ▶  $b_i \sim N(0, G)$ , sendo  $G$  a matriz de covariância dos parâmetros de efeito aleatório;
- ▶  $\epsilon_i \sim N(0, R_i)$ , sendo  $R_i = \sigma^2 I$  a matriz de covariância de resíduos com  $I$  a matriz identidade.

# Modelos Lineares Generalizados Mistos

- ▶ **Efeitos fixos** descrevem características populacionais ( $\beta$ ).
- ▶ **Efeitos aleatórios** descrevem características individuais ( $b_i$ ).
- ▶ Portanto, modelos mistos permitem construir **trajetórias individuais**.
- ▶ Podemos indentificar **perfis** acima e abaixo da média populacional.




Figura 27. Observações tomadas em diferentes tempos. Dados extraídos do pacote forestmangr no R.

# Modelos Lineares Generalizados Mistos - Exemplo 5

- ▶ O problema consiste em **estimar o volume total** de árvores de um inventário florestal realizado em múltiplas ocasiões.
- ▶ **Dados** disponíveis:
  - ▶ Volume ( $V$ ) → Resposta.
  - ▶ Idade ( $I$ ) → Preditora.




Figura 28. Exemplo 5. Dados extraídos do pacote forestmangr no R.

# Modelos Lineares Generalizados Mistos - Exemplo 5

- ▶ O problema consiste em **estimar o volume total** de árvores de um inventário florestal realizado em múltiplas ocasiões.
- ▶ **Dados** disponíveis:
  - ▶ Volume ( $V$ ) → Resposta.
  - ▶ Idade ( $I$ ) → Preditora.




Figura 29. Exemplo 5. Dados extraídos do pacote forestmangr no R.



# Modelos Lineares Generalizados Mistos - Exemplo 5

- ▶ O problema consiste em **estimar o volume total** de árvores de um inventário florestal realizado em múltiplas ocasiões.
- ▶ **Dados** disponíveis:
  - ▶ Volume ( $V$ ) → Resposta.
  - ▶ Idade ( $I$ ) → Preditora.
- ▶ Modelo linear misto **teórico**:

$$V_i = (\beta_0 + b_{0i}) + (\beta_1 + b_{1i})I_i + \epsilon_i.$$

- ▶ **Valor esperado:**

$$E(V_i|b_{0i}, b_{1i}) = (\hat{\beta}_0 + b_{0i}) + (\hat{\beta}_1 + b_{1i})I_i.$$




Figura 30. Exemplo 5. Dados extraídos do pacote forestmangr no R.

# Modelos Não Lineares

- ▶ Descreve uma **relação não linear** entre a variável resposta ( $y_i$ ) e a variável preditora ( $x_i$ ).
- ▶ É uma **função não linear** do vetor de parâmetros ( $\theta$ ):

$$y_i = f(\theta, x_i) + \epsilon_i.$$

- ▶ **Definição:** modelo é não linear se pelo menos uma das derivadas parciais de  $f(\cdot)$  em relação a cada parâmetro do vetor  $\theta$  envolve parâmetro desconhecido.




Figura 31. Valor esperado da resposta. Extraído de Walmes Zeviani. Disponível em: <http://leg.ufpr.br/walmes/Tikz>.

# Modelos Não Lineares

## ► Vantagens:

- Escolha do modelo é baseada no comportamento do fenômeno;
- Parâmetros interpretáveis;
- Modelos mais parcimoniosos;
- Predições mais confiáveis para fora do domínio da preditora.

## ► Desvantagens:

- Necessidade de conhecimento técnico do fenômeno em estudo;
- Requer procedimentos iterativos de estimação;
- Métodos de inferências são aproximados.




Figura 32. Modelo linear e não linear. Extraído de Walmes Zeviani. Disponível em: <http://leg.ufpr.br/walmes/Tikz>.

# Modelos Não Lineares Generalizados

- ▶ É uma **extensão** dos modelos lineares generalizados.
- ▶ O **valor esperado** da resposta é modelado como uma função não linear do vetor de parâmetros  $\theta$ :

$$y_i = f(\theta, x_i) + \epsilon_i,$$

em que:

- ▶  $y_i \sim f_e(\cdot)$ , ou seja, pertence a família exponencial.




Figura 33. Modelo não linear generalizado. Extraído de Walmes Zeviani. Disponível em: <http://leg.ufpr.br/walmes/Tikz>.

# Modelos Não Lineares Generalizados Mistos

- ▶ É uma **extensão** dos modelos não lineares generalizados.
- ▶ O **valor esperado** da resposta é modelado como uma função não linear do vetor de parâmetros  $\theta$ :

$$y_i = f(W_i) + \epsilon_i,$$

em que:

- ▶  $W_i = X_i\beta + Z_i b_i$ ;
- ▶  $y_i \sim f_e(\cdot)$ , ou seja, pertence a família exponencial.




Figura 34. Modelo misto. Extraído de Walmes Zeviani. Disponível em: <http://leg.ufpr.br/walmes/Tikz>.

# Modelos Multivariados

- ▶ Modelo de regressão **multivariado** relaciona  $r = 1, \dots, R$  variáveis:

$$y_{ir} = \beta_{0r} + \beta_{1r}x_{ijr} + \dots + \beta_{pr}x_{ipr} + \epsilon_{ir}$$

# Modelos Multivariados

- Modelo de regressão **multivariado** relaciona  $r = 1, \dots, R$  variáveis:

$$y_{ir} = \beta_{0r} + \beta_{1r}x_{ijr} + \dots + \beta_{pr}x_{ipr} + \epsilon_{ir}$$

$$y_{ir} = \beta_{0r} + \underbrace{\beta_{1r}x_{ijr}}_{\text{observações correlacionadas}} + \dots + \beta_{pr}x_{ipr} + \epsilon_{ir}$$

# Modelos Multivariados

- Modelo de regressão **multivariado** relaciona  $r = 1, \dots, R$  variáveis:

$$y_{ir} = \beta_{0r} + \beta_{1r}x_{ijr} + \dots + \beta_{pr}x_{ipr} + \epsilon_{ir}$$

$$y_{ir} = \beta_{0r} + \underbrace{\beta_{1r}x_{ijr}}_{\text{observações correlacionadas}} + \dots + \beta_{pr}x_{ipr} + \epsilon_{ir}$$

$$y_{ir} = \beta_{0r} + \underbrace{\beta_{1r}x_{ijr} + \dots + \beta_{pr}x_{ipr}}_{\text{covariáveis correlacionadas}} + \epsilon_{ir}$$



# Modelos Multivariados

- Modelo de regressão **multivariado** relaciona  $r = 1, \dots, R$  variáveis:

$$y_{ir} = \beta_{0r} + \beta_{1r}x_{ijr} + \dots + \beta_{pr}x_{ipr} + \epsilon_{ir}$$

$$y_{ir} = \beta_{0r} + \underbrace{\beta_{1r}x_{ijr}}_{\text{observações correlacionadas}} + \dots + \beta_{pr}x_{ipr} + \epsilon_{ir}$$

$$y_{ir} = \beta_{0r} + \underbrace{\beta_{1r}x_{ijr} + \dots + \beta_{pr}x_{ipr}}_{\text{covariáveis correlacionadas}} + \epsilon_{ir}$$

$$\underbrace{y_{ir}}_{\text{respostas correlacionadas}} = \beta_{0r} + \beta_{1r}x_{ijr} + \dots + \beta_{pr}x_{ipr} + \epsilon_{ir}$$

# Modelos Multivariados

- ▶ Modelo multivariado modela **múltiplas respostas** simultaneamente.
- ▶ A potencial **correlação** entre respostas é levada em consideração.
- ▶ Medidas de **incertezas** podem ser estimadas de forma adequada.




Figura 35. Variáveis respostas.

# Modelos Multivariados - MCGLM

- ▶ BONAT e JØRGENSEN desenvolveram a classe **Multivariate Covariance Generalized Linear Models** (MCGLM):
  - ▶ Bastante flexível para modelar dados correlacionados univariados e multivariados;
  - ▶ Considerando respostas de diferentes naturezas;
  - ▶ E permite definir diversas estruturas de covariância.
- ▶ MCGLM é baseado em suposições de **segunda ordem**: média e covariância.
- ▶ **Covariâncias** são introduzidas usando uma combinação linear de matrizes conhecidas.
- ▶ Portanto, é uma classe de modelos com **grande potencial** no manejo florestal.

# Modelos Multivariados - MCGLM

- **Formulação genérica** para um MCGLM é dada por

$$E(Y) = M = \{g_1^{-1}(X_1\beta_1), \dots, g_R^{-1}(X_R\beta_R)\},$$

$$Var(Y) = C = \Sigma_R \otimes \Sigma_b.$$

A matriz de covariância  $\Sigma_r$  para cada resposta é dada por

$$\Sigma_r = V(\mu_r; p_r)^{1/2} h\{\Omega(\tau_r)\} V(\mu_r; p_r)^{1/2},$$

$\Sigma_R$  é uma  $N \times N$  matriz de covariância dentro da resposta  $r = 1, \dots, R$ ;  $\Sigma_b$  é uma matriz de correlação entre respostas;  $V(\mu_r; p_r)$  é uma matriz diagonal, cujas entradas principais denotam a função de variância;  $p_r$  é um vetor de parâmetros de potência;  $h\{\Omega(\tau_r)\} = \tau_0 Z_0 + \dots + \tau_D Z_D$ ; e  $h$  é uma função de ligação de covariância.

# Modelos Multivariados - Exemplo 6

## ► Preditor linear:

- Resposta: altura ( $H$ ) e volume ( $V$ ).
- Covariável: diâmetro ( $D$ ).

$$E(H_i) = \hat{\beta}_0 + \hat{\beta}_1 D_i + \hat{\beta}_2 D_i^2 + \hat{\beta}_3 D_i^3$$

$$E(V_i) = \exp(\hat{\beta}_0 + \hat{\beta}_1 D_i + \hat{\beta}_2 D_i^2)$$

## ► Preditor linear de matriz:

- Modelagem da variância é uma função de  $D$ .
- Função de variância inserida para  $V$ .

$$\Omega(\tau_r) = \hat{\tau}_0 I$$




Figura 36. Extraído de Fiorentin et al. (2019).

# Modelos Multivariados - Exemplo 6




Figura 37. Extraído de Fiorentin et al. (2019).

# Modelos Multivariados - Exemplo 6

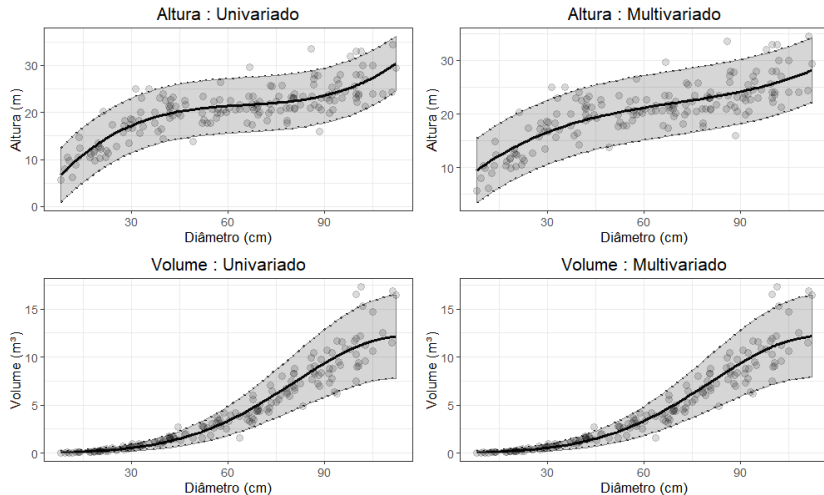


Figura 38. Extraído de Fiorentin et al. (2019).

# Outras Classes de Modelos

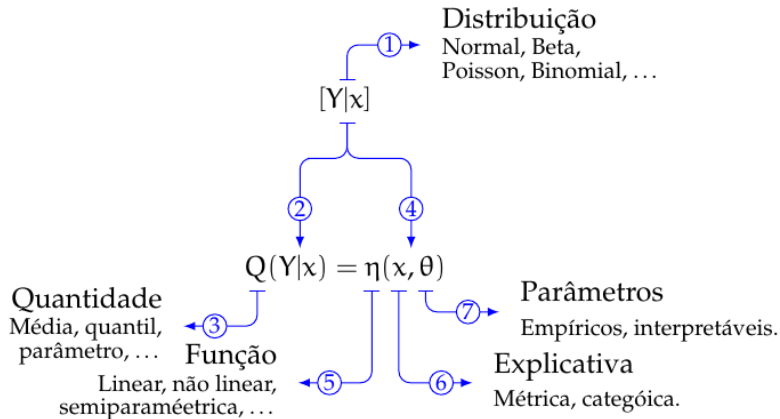


Figura 39. Componentes do modelo. Extraído de Walmes Zeviani. Disponível em: <http://leg.ufpr.br/walmes/Tikz>.



# Outras Classes de Modelos

- ▶ Há diversas classes de modelos:
  - ▶ Modelos Não Lineares;
  - ▶ Modelos Não Lineares Generalizados;
  - ▶ Modelos Não Lineares Generalizados Mistos;
  - ▶ Entre outros.
- ▶ Modelos de *Statistical Learning*:
  - ▶ *Neural Network*;
  - ▶ *Support Vector Machine*;
  - ▶ *Random Forest*;
  - ▶ Entre outros.
- ▶ Características dos modelos:
  1. **Interpretabilidade.**
  2. **Flexibilidade.**

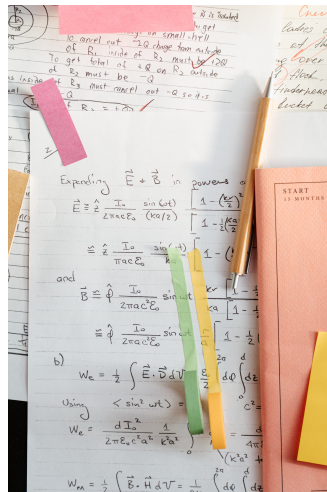


Figura 40. Foto de cottonbro no Pexels

# Outras Classes de Modelos




Figura 41. Relação entre interpretabilidade e flexibilidade de classes de modelos. Figura produzida pelo Autor.

# Outras Classes de Modelos - *Softwares*

- ▶ Opções de **softwares pagos**:
  - ▶ SPSS;
  - ▶ SAS;
  - ▶ Stata;
  - ▶ Minitab;
  - ▶ Entre outros.
- ▶ Opções de **softwares não pagos**:
  - ▶ R.
- ▶ Linguagens de **programação**:
  - ▶ R;
  - ▶ Python;
  - ▶ Julia.



Figura 42. Logo do R.

# Considerações Finais

## Principais tópicos

- ▶ Modelagem de **relações dendrométricas** é fundamental na análise de dados.
- ▶ Natureza das variáveis e estrutura dos dados indica o **modelo estatístico** adequado.
- ▶ Portanto, é importante desenvolver **habilidades estatísticas**.



Figura 43. Foto de Anthony no Pexels.

*That's all folks!!!*

► **Contato:**

- **E-mail:** [luanfiorentin@hotmail.com](mailto:luanfiorentin@hotmail.com)
- **Instagram:** [luann\\_fiorentin](#)
- **Instagram :** [fordata4d](#)




Figura 44. Conheça a For Data!

*That's all folks!!!*



Figura 45. Foto de Pexels